

Monitor Predictivo del Mercado Laboral Colombiano

Integración de datos DANE + FILCO + SENA y predicción de la tasa de desocupación a 6 meses con modelo Holt-Winters.

EQUIPO

Andrés Zambrano

Daniers Solarte

Deivid Alvarado

Luna Mideros

Ingeniería de Software · Universidad Cooperativa de Colombia

¿Qué resolvemos?

**Datos laborales dispersos en +70
archivos sin integración ni predicción
pública.**

Construimos el pipeline ETL que los unifica y un modelo de ML que proyecta el desempleo colombiano con un error de **0.43 puntos porcentuales**, publicado en un dashboard de acceso libre.

🚩 EL PROBLEMA

- La **tasa de desocupación nacional** oscila entre 8 % y 20 %, con alta variación estacional y regional. Es un indicador crítico sin herramienta pública de predicción.
- Los datos existen pero están dispersos en **33 PDFs del DANE, 40+ archivos Excel de FILCO** y **una API del SENA** sin ningún punto de integración.
- El MinTrabajo y el SENA diseñan programas con información fragmentada y desactualizada, **sin visibilidad anticipada** del comportamiento del mercado laboral.

Pregunta central: ¿cómo se va a comportar la tasa de desocupación en los próximos 6 meses?

OBJETIVO

Integrar datos del **DANE, FILCO y SENA** en un pipeline ETL automatizado, aplicar un modelo **Holt-Winters** para proyectar la tasa de desocupación a **6 meses con IC al 90 %**, y publicar los resultados en un **dashboard web de acceso público** con predicciones verificables.

Datos abiertos

Machine Learning

Impacto público

Open source

DANE · GEIH

Boletines de mercado laboral

FORMATO	PDF — parseo regex + pdfplumber
ARCHIVOS	33 boletines mensuales
PERÍODO	Mayo 2023 → Feb 2026
VARIABLES	Tasa desocupación · Tasa ocupación · TGP
TRATAMIENTO	Extracción dual: texto plano + tablas en primeras 5 páginas. Validación de rangos [5 %–25 %].

FILCO

Informalidad laboral GEIH-EISS

FORMATO	Excel (.xls / .xlsx)
ARCHIVOS	40+ anexos trimestrales
PERÍODO	Ene 2022 → Feb 2026
VARIABLES	Tasa informalidad — 13 ciudades
TRATAMIENTO	Normalización de columnas con ñ, conversión numérica, ANOVA entre ciudades.

SENA

Inscritos por área y ocupación

FORMATO	API Socrata — datos.gov.co
ID DATASET	<code>8pqf-rmzr</code>
PERÍODO	2019 → 2020
VARIABLES	Ocupación · inscritos 2019 vs 2020
TRATAMIENTO	Consulta REST directa, top-10 ocupaciones por demanda, comparación interanual.

Los tres datasets se integran en un **esquema estrella PostgreSQL 15** de 7 tablas (3 dimensiones + 3 hechos + predicciones) cargadas automáticamente con **PySpark JDBC** dentro de un entorno Docker.

FASE 1

DataSource

PDF · Excel · API REST

FASE 2

DataProcess

Limpieza · Validación

FASE 3

DataTransform

PySpark · PostgreSQL

FASE 4

DataProduct

Modelo · Dashboard

Modelo — Holt-Winters

Suavizamiento exponencial triple que captura **tendencia + estacionalidad** de la tasa de desocupación.

- Partición: **80 % train / 20 % test**
- Parámetros: α , β , γ optimizados automáticamente
- Intervalo de confianza: **90 % ($\pm 1.645\sigma$)**
- Fallback: Prophet (si CmdStan está disponible)

[statsmodels · ExponentialSmoothing](#)**Base de Datos — Esquema Estrella**

PostgreSQL 15 con 7 tablas: **dim_periodo**, **dim_departamento**, **dim_ciudad** + **fact_mercado_laboral**, **fact_informalidad**, **fact_demanda_sena** + **prediccion_td**.

Carga automática con **PySpark JDBC**. Adminer para exploración. Todo en Docker Compose con 3 contenedores.

[Docker · PySpark · PostgreSQL 15](#)**Dashboard — Next.js en Producción**

Aplicación web con **5 secciones interactivas**:

- Serie histórica TD (2022–2026)
- Forecast con banda de confianza
- Informalidad por ciudad · Análisis SENA
- Métricas del modelo (MAE, RMSE)

Desplegado en **Vercel**, acceso libre y gratuito.

[economia-empleo.vercel.app](#)

MÉTRICAS DEL MODELO · CONJUNTO DE PRUEBA

0.43

MAE · puntos porcentuales

0.54

RMSE · puntos porcentuales

18

Tests pytest pasados ✓

90%

Confianza del intervalo

DEMO EN PRODUCCIÓN — ACCESO LIBRE

economia-empleo.vercel.app

Dashboard con serie histórica, forecast a 6 meses, análisis de informalidad por ciudad y métricas del modelo en tiempo real.

Tecnología: **Next.js** · **TypeScript** · **Vercel**

HALLAZGOS PRINCIPALES

- El modelo acierta dentro de **± 0.43 pp en promedio** — para un indicador que fluctúa ± 12 pp esto equivale a una precisión del 96 %.
- Informalidad en **Cúcuta supera el 65 %**, más del doble que Bogotá (31 %). ANOVA confirma diferencias significativas entre ciudades ($p < 0.05$).
- El SENA redujo inscritos en **18 % entre 2019 y 2020** en ocupaciones de manufactura, coincidiendo con el pico de desempleo pandémico.

MINTRABAJO · DNP**Política pública con 6 meses de anticipación**

Proyecciones cuantitativas de TD permiten diseñar programas de empleo y subsidios antes de que el desempleo se materialice, no después.

SENA**Articulación formación ↔ demanda laboral**

El análisis de inscritos por ocupación revela qué programas aumentan o disminuyen su matrícula, orientando la oferta educativa según la dinámica real del mercado.

ENTIDADES TERRITORIALES · 5 CIUDADES**Intervenciones diferenciadas por ciudad**

El análisis ANOVA de informalidad (Bogotá, Medellín, Cali, Barranquilla, Cúcuta) evidencia que las brechas son estadísticamente significativas y requieren políticas distintas.

CIUDADANOS · INVESTIGADORES · PERIODISTAS**Acceso libre a análisis que antes no existían**

Dashboard público gratuito. Pipeline open source y reproducible en GitHub, aplicable a cualquier indicador del mercado laboral colombiano.

Beneficiarios directos: desempleados · trabajadores informales · mujeres · jóvenes
Sostenibilidad: pipeline automatizado · CI/CD GitHub Actions · Docker · Vercel (sin costo operativo)

CÓDIGO FUENTE

github.com/andresZam12/proyectoMINTIC

Repositorio público con estructura nivel Intermedio: notebooks, src/, tests, CI/CD, docs/ completos.

DEMO EN VIVO

economia-empleo.vercel.app

Dashboard interactivo en producción. Acceso inmediato sin instalación.

RECURSOS DISPONIBLES PARA REVISIÓN TÉCNICA



README.md completo

Instalación, orden de ejecución, variables de entorno, demo link



5 Notebooks Jupyter (01–05)

EDA · Limpieza · Análisis · Modelo · Reportes — todos ejecutables



Código fuente modular (src/)

config · data_cleaning · feature_engineering · model_training · model_evaluation



18 Tests automatizados (pytest)

Calidad de datos + inferencia del modelo · CI/CD en GitHub Actions



Documentación técnica (docs/)

Arquitectura · diccionario de datos · fuentes · CRISP-ML(Q) · conclusiones

VALOR DIFERENCIAL DEL PROYECTO

**Convertimos +70 archivos dispersos del DANE, FILCO y SENA
en un dashboard predictivo público que proyecta el desempleo
colombiano
con un error de 0.43 puntos porcentuales y sin costo de acceso.**

DEMO

economia-empleo.vercel.app

REPOSITORIO

github.com/andresZam12/proyectoMINTIC

NIVEL

Intermedio · Reto 5

Andrés Zambrano · Daniers Solarte · Deivid Alvarado · Luna Mideros
Ingeniería de Software · Universidad Cooperativa de Colombia

